COMILLAS
UNIVERSIDAD PONTIFICIA

ICAI

GRADO EN INGENIERÍA MATEMÁTICA E INTELIGENCIA ARTIFICIAL

ANEXO B

De-novo molecular design with AI

Author: Enrique Fernández-Baíllo Rodríguez de Tembleque

Director: Simón Rodríguez Santana

Co-Director: Andrés Occhipinti Liberman

Firmado por RODRIGUEZ SANTANA SIMON - ***4141** el día 15/01/2026 con un certificado emitido por AC FNMT Usuarios

Madrid, Enero 2026

Andrés Occhipinti

Índice

1 Introducción **1**

2 Trabajos Relacionados **2**
2.1 Representación Molecular y Modelos Generativos 2
2.2 Trabajo Fundacional y Metodología Base 2
2.3 Identificación del Vacío en el Estado del Arte 3

3 Motivación y Objetivos **4**
3.1 Motivación 4
3.2 Objetivos 4
3.3 Alineación con los ODS 5

4 Metodología de trabajo **6**
4.1 Cronograma 6

5 Recursos **7**
5.1 Software 7
5.2 Hardware 7
5.3 Set de datos 8

6 Bibliografía **9**

1 Introducción

El objetivo de este proyecto es diseñar una arquitectura de diseño molecular *de-novo*, alineada con el estado del arte, para abordar problemas de optimización farmacológica. Específicamente, se busca determinar la representación molecular y la arquitectura de red neuronal que permitan explotar al máximo los recursos disponibles, para extraer la máxima información posible en escenarios donde la escasez de grandes bases de datos de bioactividad es un problema común.

Este trabajo se enmarca en la investigación de nuevas dianas terapéuticas, tomando como caso de estudio principal la inhibición de la quinasa DYRK1A, una proteína relacionada con diversas afecciones neurológicas (como el síndrome de Down o el Alzheimer). La finalidad es proponer moléculas candidatas que actúen como fármacos antagonistas con alta afinidad. Adicionalmente, la metodología desarrollada está diseñada para ser transferible a otras dianas emergentes, contemplándose su aplicación al diseño de fármacos para la tripanosomiasis africana en caso de que los datos experimentales estén disponibles durante el desarrollo del proyecto.

El diseño *de-novo* de fármacos cambia el paradigma del diseño molecular, tradicionalmente basado en modificar iterativamente moléculas conocidas. La tarea de proponer una molécula que maximice ciertas características deseadas se puede definir como un problema de optimización de funciones objetivo y restricciones desconocidas *(black-box)*. Es por la complejidad de este problema de optimización que tradicionalmente resultaba de extrema dificultad proponer moléculas completamente nuevas, por lo que siempre se partía de las ya conocidas, limitando enormemente la exploración. Los algoritmos *de-novo* son capaces de resolver este problema de optimización proponiendo moléculas desde cero, y estas técnicas han visto un enorme crecimiento en su eficiencia con los recientes avances en el campo de la inteligencia artificial.

El *dataset* de trabajo se compone de pares molécula-afinidad. Dado que el número de inhibidores conocidos para dianas específicas suele ser limitado (en el orden de miles, no millones), se presenta un reto de modelado importante. Se experimentará con diferentes formas de representación de la molécula como input, y con diferentes arquitecturas y técnicas de regularización para intentar maximizar la capacidad de generalización del modelo, explotando al máximo la información latente en los datos disponibles.

El valor diferencial de este trabajo reside en la adaptación de técnicas *state-of-the-art* emergentes a este contexto de recursos limitados. De resultar satisfactoria, esta metodología permitiría acelerar el diseño de fármacos no solo para las afecciones neurológicas estudiadas inicialmente, sino para cualquier otra patología donde la escasez de datos históricos sea un factor limitante para el uso de Inteligencia Artificial convencional.

2 Trabajos Relacionados

Esta sección revisa el estado del arte en representaciones moleculares y modelos generativos, y sitúa este proyecto dentro de una línea de investigación específica iniciada por el grupo de investigación de referencia.

2.1 Representación Molecular y Modelos Generativos

El éxito de cualquier modelo de aprendizaje profundo aplicado a la química depende fundamentalmente de cómo se representan las moléculas para que sean interpretables por la máquina. Según revisan Wigh et al. (2022), existen diversas estrategias, desde descripciones basadas en grafos hasta cadenas de texto simplificadas (SMILES), siendo estas últimas las más utilizadas en modelos de procesamiento de lenguaje natural. Li et al. (2022) profundizan en cómo estas representaciones permiten no solo la predicción de propiedades, sino la generación de nuevas entidades químicas con características optimizadas.

En el ámbito del diseño *de-novo*, los modelos generativos han demostrado ser herramientas poderosas para explorar el vasto espacio químico. Revisiones recientes, como la de Odah (2025) y Meyers et al. (2021), destacan cómo arquitecturas basadas en Redes Neuronales Recurrentes (RNN) y, más recientemente, Transformers, son capaces de aprender la sintaxis química para proponer estructuras válidas. Un ejemplo clásico de esta capacidad es el uso de memorias a corto y largo plazo (LSTM) para la generación molecular, demostrado por Grisoni et al. (2020), o enfoques que combinan la búsqueda de árbol de Monte Carlo (MCTS) con generadores neuronales, como el ChemTSv2 propuesto por Ishida et al. (2023).

Para validar y aplicar estos modelos en el descubrimiento de fármacos, la comunidad científica ha establecido marcos de referencia estandarizados como *GuacaMol* (Brown et al., 2019). Sin embargo, el desafío actual reside en dirigir esta generación hacia dianas biológicas concretas. En este sentido, Wang et al. (2025) destacan el papel fundamental del *transfer learning*. Su investigación demuestra que pre-entrenar modelos en espacios químicos vastos y genéricos, para luego realizar un ajuste fino (*fine-tuning*) con datos específicos de la diana, es una estrategia eficaz. Este enfoque es corroborado por Khater et al. (2025), quienes aplican técnicas similares de optimización para mejorar las propiedades farmacológicas de los candidatos generados.

2.2 Trabajo Fundacional y Metodología Base

Este proyecto se construye sobre la metodología probada y desarrollada por el grupo de investigación en el estudio reciente de González-García et al. (2025). En dicho trabajo, los autores desarrollaron con éxito una arquitectura de diseño *de-novo* impulsada por IA para el descubrimiento de inhibidores no tóxicos de la quinasa DYRK1A.

La relevancia de González-García et al. (2025) para este proyecto es fundamental, ya que proporciona el marco arquitectónico base (flujo de trabajo de generación y filtrado).

El presente trabajo busca extender y refinar esta metodología, evaluando su robustez y explorando nuevas estrategias de regularización para mejorar su rendimiento en escenarios donde la cantidad de datos es el factor crítico.

2.3 Identificación del Vacío en el Estado del Arte

A pesar de los avances descritos, existe una limitación significativa en la literatura actual. La mayoría de los modelos generativos de gran escala se benefician de la existencia de bases de datos masivas. Sin embargo, en el descubrimiento de fármacos para dianas específicas o enfermedades menos estudiadas, estos volúmenes de datos raramente están disponibles.

El vacío que este proyecto aborda es la optimización del diseño molecular en el régimen de escasez de datos (*low-data regime*). Aunque existen datos para dianas como DYRK1A, el volumen (en el orden de miles de muestras) sigue siendo reducido en comparación con los estándares habituales de Deep Learning. Este proyecto se centra en validar qué arquitecturas son capaces de extraer la mayor cantidad de información y generalizar correctamente en estas condiciones, un problema que sigue siendo un desafío abierto y prevalente en el diseño farmacológico actual.

3 Motivación y Objetivos

3.1 Motivación

El desarrollo de fármacos para enfermedades complejas, ya sean neurológicas o infecciosas, se enfrenta a menudo a la dificultad de identificar moléculas que interactúen eficazmente con dianas biológicas específicas. En el caso de dianas como la quinasa DYRK1A, implicada en procesos cognitivos y neurodegenerativos, o en potenciales dianas de enfermedades tropicales, la investigación tradicional es costosa y lenta.

Desde una perspectiva técnica, la motivación central de este trabajo es abordar el desafío del *low-data regime* en Inteligencia Artificial aplicada a la química. Entrenar modelos generativos eficaces con datasets limitados (del orden de mil a dos mil compuestos conocidos) es una tarea compleja pero necesaria, ya que es el escenario más común al investigar nuevas dianas terapéuticas.

Este trabajo busca demostrar que, mediante un diseño cuidadoso de arquitecturas y el uso de técnicas avanzadas, es posible explotar los recursos disponibles para proponer candidatos moleculares de alta calidad. Resolver este problema no solo tendría impacto en el estudio de inhibidores para DYRK1A, sino que ofrecería una herramienta metodológica valiosa para otras patologías, como la enfermedad del sueño, en caso de disponer de los datos necesarios.

3.2 Objetivos

El objetivo principal de este proyecto es diseñar y validar una arquitectura de Inteligencia Artificial Generativa capaz de realizar un diseño molecular *de-novo* eficiente, maximizando la afinidad hacia proteínas diana de interés (inicialmente DYRK1A), operando bajo un régimen de datos de entrenamiento limitados.

Para la consecución de este propósito, se establecen los siguientes objetivos secundarios:

1. **Evaluación de representaciones moleculares:** Determinar experimentalmente qué formato de entrada (SMILES, grafos moleculares, etc.) permite al modelo capturar mejor las características químicas latentes con un número reducido de muestras.

2. **Optimización de la arquitectura en *low-data*:** Implementar y comparar diferentes estrategias de regularización y arquitecturas (como RNNs, LSTMs o Transformers ligeros) para mitigar el sobreajuste (*overfitting*) y extraer la máxima información del dataset disponible.

3. **Generación de candidatos viables:** Obtener un conjunto final de moléculas generadas que no solo maximicen la afinidad teórica, sino que también sean químicamente válidas, diversas y no tóxicas, demostrando la utilidad del sistema en casos de uso reales.

3.3 Alineación con los ODS

Este proyecto se alinea con la Agenda 2030 de las Naciones Unidas, contribuyendo a los siguientes Objetivos de Desarrollo Sostenible (ODS):

- **ODS 3: Salud y Bienestar.** Al desarrollar herramientas para el descubrimiento de fármacos en enfermedades neurológicas y potencialmente infecciosas, el proyecto apoya la mejora de tratamientos y el bienestar global.
- **ODS 9: Industria, Innovación e Infraestructura.** El proyecto fomenta la innovación al aplicar tecnologías de vanguardia (IA Generativa) para optimizar procesos en el sector científico y farmacéutico.
- **ODS 10: Reducción de las Desigualdades.** Al facilitar metodologías que reducen costes y tiempos en el descubrimiento de fármacos, se contribuye a que la investigación sea más accesible, incluso para enfermedades que tradicionalmente reciben menos inversión.

4 Metodología de trabajo

La metodología adoptada para este proyecto combina la investigación teórica con el desarrollo de software experimental. Dado el carácter interdisciplinar (IA y Farmacología Computacional) y el enfoque en la optimización con recursos limitados, se ha establecido un flujo de trabajo flexible dividido en cuatro bloques principales.

Las fases y tareas principales definidas para la consecución de los objetivos son:

1. **Coordinación y Seguimiento (Transversal):** Esta tarea abarca la totalidad del proyecto. Se ha establecido una reunión de control semanal con la dirección académica para reportar progresos y recibir *feedback*. Adicionalmente, el proyecto se inició con una reunión estratégica el 4 de noviembre de 2025 con el equipo de investigación.

2. **Fundamentos del Dominio y Estado del Arte (Fase Inicial):** Durante los primeros meses, el foco se situó en la comprensión de las interacciones ligando-proteína y el estudio del trabajo de referencia de González-García et al., 2025, así como en el análisis de las propiedades del dataset de DYRK1A.

3. **Desarrollo Iterativo y Experimentación (Fase de Ejecución):** Desde el inicio del segundo cuatrimestre hasta el final del proyecto, se llevará a cabo el trabajo práctico:

   - Programación de los modelos generativos en Python/PyTorch.
   - Estudio continuo de nuevas investigaciones (como las mencionadas en el estado del arte) para integrar técnicas emergentes.
   - Ejecución de pruebas de concepto, registro de métricas y documentación de dificultades técnicas para su resolución.

4. **Redacción de la Memoria y Defensa:** La fase final implica la consolidación de resultados, la justificación de las decisiones de diseño y la escritura formal del Trabajo de Fin de Grado.

4.1 Cronograma

A continuación, se detalla la planificación temporal de las tareas descritas.

Fases / Tareas	**2025**				**2026**				
	Sep	Oct	Nov	Dic	Ene	Feb	Mar	Abr	May
Coordinación y Reuniones Semanales									
Estudio Bioquímica y DYRK1A									
Desarrollo, Programación y Experimentación									
Redacción de la Memoria									

Table 1: Cronograma de actividades del proyecto.

5 Recursos

Para la correcta ejecución de este proyecto, se han identificado y asegurado los siguientes recursos técnicos y de datos. Dada la naturaleza del problema (optimización en régimen de datos limitados), los requisitos computacionales son moderados, permitiendo una gestión local de los recursos.

5.1 Software

El desarrollo de los algoritmos de Inteligencia Artificial y el procesamiento de datos moleculares se realizará íntegramente utilizando el ecosistema de Python. Las librerías y herramientas específicas que constituirán el núcleo del desarrollo son:

- **PyTorch:** Framework principal de Deep Learning utilizado para el diseño, entrenamiento y validación de las redes neuronales generativas (RNNs/Transformers) y los modelos de predicción de afinidad.
- **RDKit:** Librería estándar de facto en quimioinformática. Se utilizará para el procesamiento de las representaciones moleculares (SMILES), cálculo de propiedades fisicoquímicas, validación de estructuras químicas y generación de *fingerprints*.
- **Pandas y NumPy:** Para la manipulación eficiente de matrices de datos y gestión de los datasets en formato tabular.
- **Scikit-learn:** Utilizado para métricas de evaluación, preprocesamiento de datos y modelos base de comparación (*baselines*).
- **Entorno de desarrollo:** Se utilizarán Jupyter Notebooks para la experimentación rápida y visualización de datos, y entornos IDE (como VS Code) para la modularización del código final.
- **Sistema Operativo:** Todo el entorno de desarrollo y ejecución de modelos se desplegará sobre Ubuntu Linux.

5.2 Hardware

La principal ventaja de este régimen de datos es que el volumen de entrenamiento es reducido, lo que disminuye la carga computacional requerida en comparación con situaciones de *Big Data*. Esto permite entrenar modelos en un equipo personal y realizar iteraciones rápidas para explorar numerosas alternativas de arquitectura e hiperparámetros.

El equipo en el que se llevará a cabo todo el procedimiento cumple con los requisitos para aceleración por GPU mediante CUDA. Las especificaciones técnicas del equipo disponible son:

Componente	Especificación
Procesador (CPU)	`Intel(R) Core(TM) i7-10870H`
Tarjeta Gráfica (GPU)	`NVIDIA GeForce RTX 3060 Laptop GPU (6 GB)`
Memoria RAM	`32,0 GB (31,8 GB usable)`
Sistema Operativo	`Windows 10 (con soporte WSL2 para Linux)`

Table 2: Especificaciones del hardware local utilizado para el entrenamiento.

5.3 Set de datos

El proyecto utilizará datos provenientes de bases de datos públicas como ChEMBL. La estrategia de datos se centra en maximizar el aprendizaje a partir de conjuntos limitados.

Dataset Principal (DYRK1A)

Como caso de estudio central y para el desarrollo de la arquitectura, se utilizará el dataset de inhibidores de la quinasa DYRK1A empleado en el estudio de referencia de González-García et al., 2025. Este conjunto de datos representa fielmente el desafío del *low-data regime* (menos de 2000 muestras), siendo ideal para validar las estrategias de regularización.

Sus características clave son:

- **Volumen:** 1782 inhibidores activos.
- **Representación:** Las moléculas están descritas mediante notación SMILES (columna `Smiles`), que servirá como entrada para los modelos generativos.
- **Variable Objetivo:** La afinidad de unión se mide mediante el valor pChEMBL, permitiendo la regresión sobre una métrica continua.
- **Origen:** Datos experimentales de bioactividad (Target ChEMBL ID: CHEMBL2292).

6 Bibliografía

Brown, N., Fiscato, M., Segler, M. H. S., & Vaucher, A. C. (2019). Guacamol: Benchmarking models for de novo molecular design. *Journal of Chemical Information and Modeling*, *59*(3), 1096–1108. https://doi.org/10.1021/acs.jcim.8b00839

González-García, E., Varas, P., González-Naranjo, P., Ulzurrun, E., Marcos-Ayuso, G., Pérez, C., Páez, J. A., Rios Insua, D., Rodríguez-Santana, S., & Campillo, N. E. (2025). Ai-driven de novo design and development of nontoxic dyrk1a inhibitors. *Journal of Medicinal Chemistry*, *68*(2), 1013–1032. https://doi.org/10.1021/acs.jmedchem.4c01822

Grisoni, F., Moret, M., Lingwood, D., & Schneider, G. (2020). De novo molecular design with generative long short-term memory. *Molecular Informatics*, *39*(4), 1900115. https://doi.org/10.1002/minf.201900115

Ishida, S., Terayama, K., Sumita, M., Novick, S. J., Fukunishi, Y., & Tsuda, K. (2023). Chemtsv2: Functional molecular design using de novo molecule generator. *Journal of Cheminformatics*, *15*(1), 71. https://doi.org/10.1186/s13321-023-00742-w

Khater, T., et al. (2025). Generative artificial intelligence based models optimization towards molecule design enhancement. *Journal of Chemical Information and Modeling*, *17*(1), 14. https://doi.org/10.1186/s13321-025-01059-4

Li, Z., Wang, S., Lin, Y., et al. (2022). Deep learning methods for molecular representation and property prediction. *Drug Discovery Today*, *27*(12), 103373. https://doi.org/10.1016/j.drudis.2022.103373

Meyers, J., Fabian, B., & Brown, N. (2021). De novo molecular design and generative models. *Drug Discovery Today*, *26*(11), 2707–2715. https://doi.org/10.1016/j.drudis.2021.05.019

Odah, M. (2025). Artificial intelligence meets drug discovery: A systematic review on ai-powered target identification and molecular design. *Preprints*, 2025030912. https://doi.org/10.20944/preprints202503.0912.v1

Wang, Y., Guo, M., Chen, X., & Ai, D. (2025). Screening of multi deep learning-based de novo molecular generation models and their application for specific target molecular generation. *Scientific Reports*, *15*(1), 2828. https://doi.org/10.1038/s41598-025-86840-z

Wigh, D. S., Goodman, J. M., & Lapkin, A. A. (2022). A review of molecular representation in the age of machine learning. *WIREs Computational Molecular Science*, *12*(5), e1603. https://doi.org/10.1002/wcms.1603